Analyse Comparative d'Algorithmes d'Optimisation Boîte Noire sur le Benchmark BBOB

Iliass Erahouten et Aya Eddib
Département d'Informatique
École d'Ingénieurs du Littoral Côte d'Opale (EILCO)
Iliass.Erahouten@etu.eilco.univ-littoral.fr, Aya.Eddib@etu.eilco.univ-littoral.fr

***Résumé*—Ce travail présente une analyse comparative de trois algorithmes d'optimisation boîte noire sur la suite de benchmarks BBOB : BIPOP-CMA-ES, PSO-BFGS et RANDOMSEARCH-5. Nous étudions leur comportement sur cinq fonctions représentatives (f1 (Sphere), f8 (Rosenbrock), f15 (Rastrigin), f20 (Schwefel) et f24 (Lunacek)), en dimension 10, couvrant des paysages unimodaux, multimodaux et à structure faible.**

L'analyse s'appuie sur les données brutes d'exécution, en considérant à la fois des runs individuels et des agrégations statistiques (notamment la médiane). Les performances sont évaluées à l'aide de courbes de convergence, de boxplots de précision finale, de fonctions de répartition empirique (ECDF), de l'Expected Running Time (ERT), de cartes de chaleur (heatmaps), ainsi que de tests statistiques de Wilcoxon.

Les résultats montrent que BIPOP-CMA-ES offre la meilleure robustesse et atteint généralement les plus faibles erreurs finales, notamment sur les fonctions complexes. PSO-BFGS se distingue par sa rapidité sur des fonctions simples ou structurées, tandis que RANDOMSEARCH-5 sert de référence de base.

Ces résultats soulignent qu'aucun algorithme n'est universellement optimal et que le choix de la méthode dépend fortement des caractéristiques du problème et du budget d'évaluations. Tous les scripts et les données sont mis à disposition sur Zenodo (DOI : https://doi.org/10.5281/zenodo.19339648) afin de garantir la reproductibilité des résultats.

I. Introduction

L'optimisation boîte noire consiste à minimiser une fonction $f : \mathbb{R}^n \to \mathbb{R}$ dont on ne connaît ni l'expression analytique ni les dérivées. Contrairement aux méthodes d'optimisation classiques basées sur le gradient, ces approches ne disposent que d'un accès limité à la fonction via des évaluations ponctuelles. Ce cadre est particulièrement pertinent dans de nombreuses applications réelles, telles que le réglage d'hyperparamètres en apprentissage automatique, la conception en ingénierie ou encore les simulations numériques coûteuses, où chaque évaluation peut représenter un coût computationnel important.

Dans ce contexte, le principal défi réside dans le choix d'un algorithme efficace, car les performances dépendent fortement des caractéristiques du problème. En effet, certaines fonctions présentent de nombreux minima locaux, ce qui peut piéger les méthodes d'optimisation, tandis que d'autres possèdent des vallées étroites ou des structures complexes rendant la convergence plus difficile. De plus, la dimension de l'espace de recherche et le budget limité en nombre d'évaluations influencent fortement l'efficacité des algorithmes.

La plateforme COCO/BBOB [1] fournit un cadre standardisé pour évaluer et comparer des algorithmes d'optimisation sur un ensemble de fonctions aux propriétés variées, allant de fonctions simples et unimodales à des fonctions hautement multimodales et trompeuses. Elle permet ainsi de réaliser des analyses reproductibles et objectives des performances des algorithmes dans des contextes contrôlés.

Dans ce travail, nous comparons trois algorithmes aux approches contrastées : BIPOP-CMA-ES [2], un algorithme évolutionnaire robuste basé sur l'adaptation de la matrice de covariance ; PSO-BFGS [3], une méthode hybride combinant exploration globale et optimisation locale ; et RANDOMSEARCH-5 [5], une stratégie aléatoire servant de référence de base.

L'objectif de cette étude est d'analyser et de comparer ces algorithmes en termes de précision, de vitesse de convergence et de robustesse, afin de mieux comprendre dans quels contextes chacun d'eux est le plus adapté. Plus précisément, nous cherchons à identifier les conditions dans lesquelles un algorithme surpasse les autres, et à mettre en évidence les compromis entre rapidité et fiabilité.

II. Contexte et État de l'Art

A. Suite de Benchmarks BBOB

La suite BBOB (Black-Box Optimization Benchmarking) comprend 24 fonctions scalaires réparties en cinq catégories : fonctions séparables, fonctions à conditionnement faible, fonctions à conditionnement élevé, fonctions multimodales à structure adéquate, et fonctions multimodales à structure inadéquate. Cette diversité permet d'évaluer les algorithmes sur des paysages d'optimisation variés et représentatifs de situations réelles.

La métrique principale utilisée est $\Delta f = f(x) - f(x^*)$, qui mesure l'écart entre la valeur obtenue et l'optimum global.

B. Algorithmes étudiés

BIPOP-CMA-ES est un algorithme évolutionnaire basé sur l'adaptation de la matrice de covariance. Il utilise deux populations de tailles différentes avec un mécanisme de redémarrage adaptatif, permettant un bon compromis entre exploration globale et exploitation locale [2].

PSO-BFGS est une approche hybride combinant l'optimisation par essaim particulaire (PSO) pour l'exploration globale et la méthode quasi-newtonienne BFGS pour le raffinement local, ce qui améliore la vitesse de convergence sur certaines classes de fonctions [3].

RANDOMSEARCH-5 repose sur un échantillonnage aléatoire uniforme de l'espace de recherche, avec un budget de $5 \times 10^7 \cdot D$ évaluations. Il constitue une méthode de référence simple, permettant de mesurer le gain apporté par des algorithmes plus sophistiqués [5].

III. Protocole Expérimental

A. Configuration

Les expériences sont réalisées en dimension $D = 10$ sur un sous-ensemble représentatif de la suite BBOB, composé de cinq fonctions couvrant différents types de paysages d'optimisation :

- **f1 (Sphere)** : fonction unimodale, séparable et convexe, représentant un cas simple de référence ;
- **f8 (Rosenbrock)** : fonction unimodale non séparable, caractérisée par une vallée étroite rendant l'optimisation plus difficile ;
- **f15 (Rastrigin)** : fonction multimodale avec de nombreux minima locaux, représentant un paysage structuré mais piégeux ;
- **f20 (Schwefel)** : fonction multimodale à structure inadéquate, présentant de fortes irrégularités et de nombreux pièges ;
- **f24 (Lunacek bi-Rastrigin)** : fonction multimodale complexe, connue pour sa difficulté élevée due à la présence de bassins d'attraction multiples.

Les données expérimentales sont extraites de l'archive officielle BBOB [6]. Pour chaque algorithme et chaque fonction, nous disposons de 15 runs indépendants, permettant d'évaluer la variabilité des performances liée au caractère stochastique des méthodes.

B. Budget d'évaluations

Le critère principal de coût est le nombre d'évaluations de la fonction objectif. Chaque algorithme est exécuté jusqu'à un budget maximal fixé par la plateforme BBOB, proportionnel à la dimension du problème ($\propto D$). Ce choix permet une comparaison équitable entre les différentes méthodes.

C. Critères de performance

Les performances sont évaluées selon plusieurs critères complémentaires :

- **Précision finale** : mesurée par $\Delta f = f(x) - f(x^*)$, correspondant à l'écart à l'optimum global ;
- **Vitesse de convergence** : analysée en fonction du nombre d'évaluations nécessaires pour atteindre un seuil donné ;
- **ERT (Expected Running Time)** : nombre espéré d'évaluations pour atteindre une précision cible, tenant compte des runs échoués ;
- **Robustesse** : évaluée à travers la variabilité des résultats sur plusieurs runs.

D. Outils d'analyse

Afin de comparer les algorithmes, nous utilisons plusieurs outils d'analyse complémentaires :

- **Courbes de convergence** : évolution de la médiane de Δf en fonction du nombre d'évaluations (échelle logarithmique) ;
- **Boxplots** : distribution des valeurs finales de Δf ;
- **ECDF** : proportion de runs atteignant un seuil donné en fonction du nombre d'évaluations ;
- **ERT** : temps d'exécution espéré pour atteindre une précision cible, métrique standard du benchmarking BBOB ;
- **Heatmaps** : visualisation globale des performances sur l'ensemble des fonctions ;
- **Tests statistiques de Wilcoxon** : comparaison par paires des algorithmes ($\alpha = 0.05$).

IV. Résultats et Discussion

A. Analyse d'un run individuel (BIPOP-CMA-ES)

Nous commençons par analyser l'exécution de l'algorithme BIPOP-CMA-ES sur une seule instance (run).

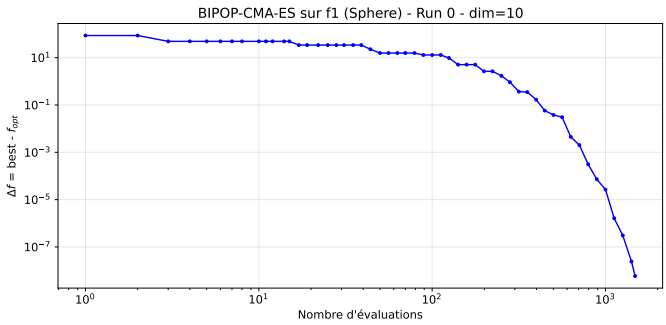

FIGURE 1. Courbe de convergence pour un run individuel de BIPOP-CMA-ES.

La figure 1 montre l'évolution de Δf en fonction du nombre d'évaluations. On observe une diminution rapide de l'erreur au début de l'exécution, suivie d'un ralentissement progressif à mesure que l'algorithme se rapproche de l'optimum.

Ce comportement est caractéristique des méthodes évolutionnaires, qui alternent des phases d'exploration globale et d'exploitation locale.

B. Analyse de plusieurs runs

Afin d'évaluer la robustesse de BIPOP-CMA-ES, nous analysons plusieurs runs indépendants sur la fonction f1 (Sphere).

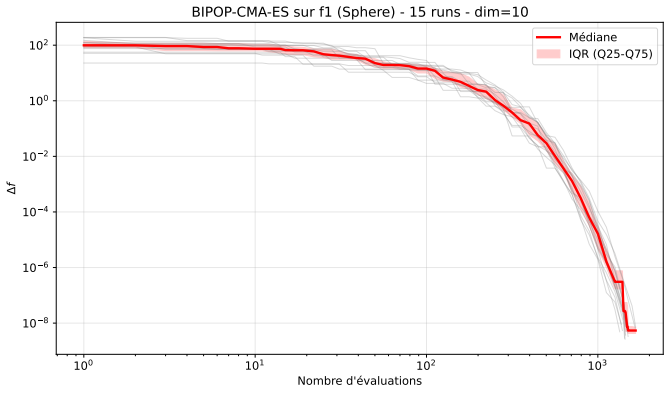

FIGURE 2. Courbes de convergence pour 15 runs indépendants de BIPOP-CMA-ES.

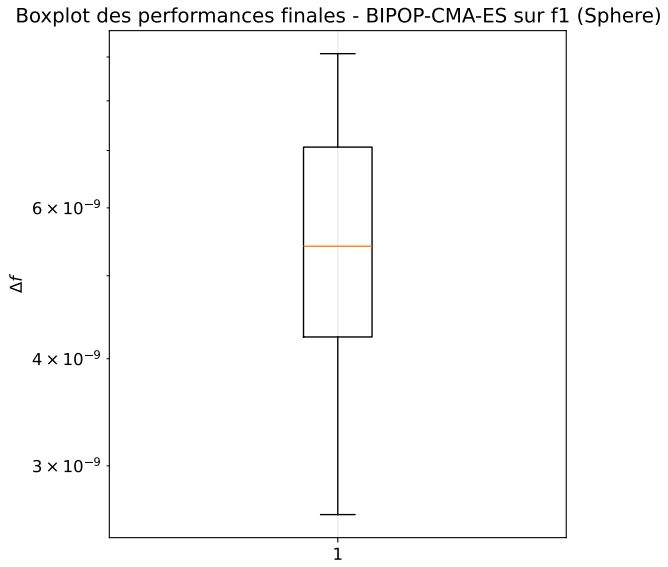

FIGURE 3. Distribution des performances finales pour f1 (boxplot).

La figure 2 montre l'évolution de Δf pour les 15 runs, ainsi que la médiane et l'intervalle interquartile (IQR). On observe que la majorité des trajectoires suivent une tendance similaire, avec une décroissance rapide de l'erreur au début, suivie d'une phase de convergence plus lente.

La faible dispersion des courbes autour de la médiane indique une bonne stabilité de l'algorithme. L'intervalle interquartile reste relativement étroit, ce qui confirme que les variations entre les runs sont limitées malgré le caractère stochastique de la méthode.

La figure 3 complète cette analyse en montrant la distribution des performances finales. On observe que les valeurs de Δf sont très faibles (de l'ordre de 10^{-9}), avec une dispersion réduite. L'absence de valeurs extrêmes significatives indique que l'algorithme converge de manière fiable vers des solutions proches de l'optimum.

Ces résultats montrent que BIPOP-CMA-ES présente une excellente robustesse sur la fonction considérée. La combinaison d'une convergence stable et d'une faible variabilité entre les runs en fait une méthode fiable pour ce type de problème.

C. Analyse par fonction

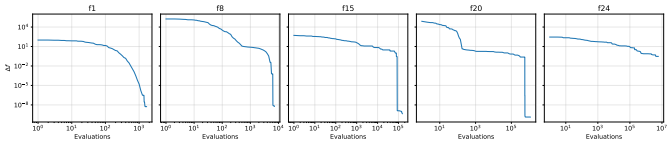

FIGURE 4. Courbes de convergence de BIPOP-CMA-ES sur les cinq fonctions BBOB (médiane sur 15 runs, dim=10).

La figure 4 présente l'évolution de la médiane de Δf en fonction du nombre d'évaluations pour BIPOP-CMA-ES sur les cinq fonctions de la suite BBOB étudiées (dim=10, 15 runs).

Sur **f1 (Sphere)**, la convergence est rapide et régulière : l'erreur Δf chute de 10^1 à 10^{-8} en environ 10^3 évaluations. Ce comportement est attendu pour une fonction unimodale et convexe, où BIPOP-CMA-ES progresse sans être piégé par des minima locaux.

Sur **f8 (Rosenbrock)**, la décroissance est plus progressive en raison de la vallée étroite qui caractérise cette fonction. L'algorithme nécessite un budget plus important ($\approx 10^4$ évaluations) pour atteindre une erreur finale de l'ordre de 10^{-8}.

Sur **f15 (Rastrigin)**, la courbe présente des paliers successifs typiques des paysages multimodaux : BIPOP-CMA-ES se retrouve temporairement bloqué dans des minima locaux avant d'en échapper grâce à son mécanisme de redémarrage adaptatif. L'erreur finale atteinte reste néanmoins très faible ($\approx 10^{-8}$, en $\approx 10^5$ évaluations).

Sur **f20 (Schwefel)**, on observe une décroissance irrégulière avec des sauts brusques, caractéristiques de la structure fortement multimodale et trompeuse de cette fonction. Malgré ces difficultés, l'algorithme converge vers une erreur finale inférieure à 10^{-9}, grâce à sa capacité d'exploration globale.

Sur **f24 (Lunacek bi-Rastrigin)**, la convergence est la plus lente et la plus difficile. La courbe décroît de manière irrégulière sur l'ensemble du budget disponible (10^7 évaluations), et l'erreur finale reste relativement élevée, autour de 10^1. La présence de multiples bassins d'attraction profonds rend cette fonction particulièrement résistante, même pour BIPOP-CMA-ES.

Ces résultats montrent que la vitesse et la qualité de convergence de BIPOP-CMA-ES dépendent fortement de la structure du paysage d'optimisation. L'algorithme excelle sur les fonctions unimodales et structurées, mais voit ses performances se dégrader progressivement face à des paysages de plus en plus complexes et multimodaux.

D. Interprétation

Les résultats obtenus mettent en évidence que BIPOP-CMA-ES est un algorithme particulièrement robuste, capable de s'adapter à différents types de paysages d'optimisation. Sa stratégie d'adaptation de la matrice de covariance lui permet de modéliser la structure du problème et d'orienter efficacement la recherche dans l'espace des solutions. Cette capacité favorise un bon équilibre entre exploration globale et exploitation locale, ce qui explique ses bonnes performances sur les fonctions complexes et multimodales.

Par ailleurs, l'analyse des multiples runs montre une faible variabilité des résultats, ce qui confirme la stabilité de l'algorithme malgré son caractère stochastique.

Cependant, cette capacité d'exploration s'accompagne d'un coût plus élevé en nombre d'évaluations. En particulier, sur les fonctions simples, l'algorithme peut converger plus lentement que des méthodes hybrides exploitant des informations locales.

Ainsi, BIPOP-CMA-ES apparaît comme une méthode fiable et robuste, particulièrement adaptée aux problèmes difficiles, mais potentiellement moins efficace lorsque le budget d'évaluations est limité.

E. Comparaison des algorithmes

Après avoir analysé en détail le comportement de BIPOP-CMA-ES, nous comparons maintenant ses performances avec celles de PSO-BFGS et RANDOMSEARCH-5 sur l'ensemble des fonctions étudiées.

Cette comparaison repose sur plusieurs outils complémentaires, incluant les courbes de convergence, les boxplots, les fonctions ECDF, l'ERT, les heatmaps ainsi que les tests statistiques de Wilcoxon. Elle permet d'obtenir une vision globale des performances relatives des algorithmes en termes de précision, de vitesse de convergence et de robustesse.

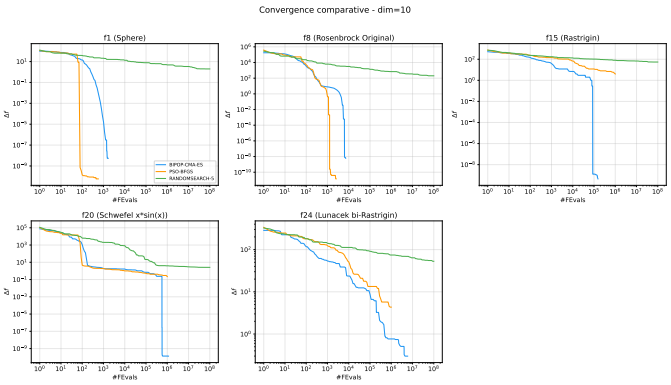

FIGURE 5. Comparaison des courbes de convergence.

1) Courbes de convergence: PSO-BFGS converge plus rapidement sur les fonctions simples, tandis que BIPOP-CMA-ES est plus robuste sur les fonctions complexes.

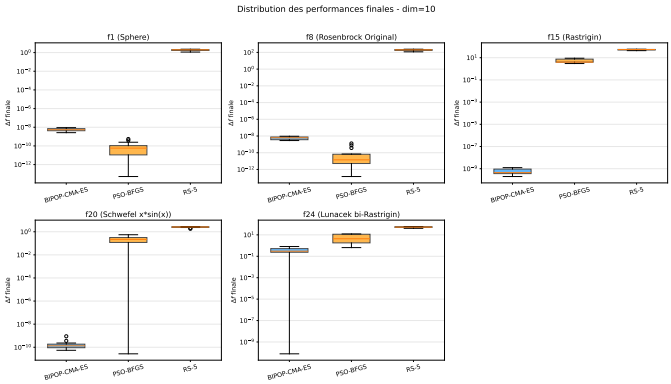

FIGURE 6. Comparaison des performances finales.

2) Boxplots: Les résultats montrent une meilleure performance de PSO-BFGS sur les fonctions simples et de BIPOP-CMA-ES sur les fonctions complexes.

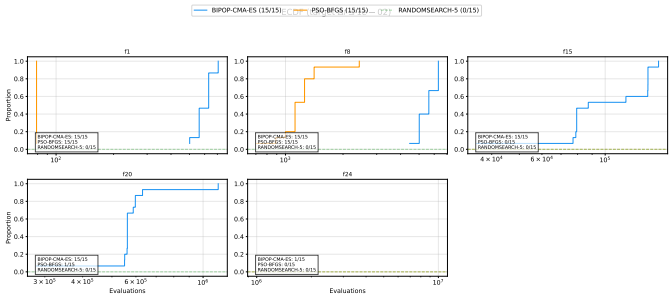

FIGURE 7. ECDF agrégée pour toutes les fonctions (target $\Delta f \leq 10^{-2}$).

3) ECDF agrégée et analyse détaillée: Les courbes ECDF sont largement utilisées dans la plateforme BBOB pour comparer de manière globale les performances des algorithmes en termes de vitesse et de taux de succès [1].

La figure 7 présente les courbes ECDF pour l'ensemble des fonctions étudiées, permettant d'évaluer simultanément le taux de succès et la vitesse de convergence des algorithmes.

L'analyse détaillée met en évidence des comportements fortement dépendants de la nature des fonctions.

Sur les fonctions simples telles que f1 (Sphere) et f8 (Rosenbrock), les deux algorithmes BIPOP-CMA-ES et PSO-BFGS atteignent un taux de succès maximal (15/15 runs), ce qui montre leur efficacité sur des paysages unimodaux. PSO-BFGS se distingue néanmoins par une convergence plus rapide, atteignant la cible avec un nombre d'évaluations plus faible.

En revanche, sur les fonctions multimodales, les différences deviennent significatives. Sur f15 (Rastrigin), BIPOP-CMA-ES atteint un taux de succès complet (15/15), tandis que PSO-BFGS échoue totalement (0/15). Ce résultat illustre la difficulté des méthodes basées sur une exploitation locale face à des paysages contenant de nombreux minima locaux.

Sur f20 (Schwefel), BIPOP-CMA-ES conserve une performance élevée (15/15), tandis que PSO-BFGS n'atteint la cible que dans un nombre très limité de runs (1/15), confirmant sa sensibilité aux fonctions irrégulières.

Enfin, sur la fonction f24 (Lunacek), extrêmement difficile, les performances chutent fortement pour tous les algorithmes. BIPOP-CMA-ES ne réussit que dans un seul run (1/15), tandis que PSO-BFGS et RANDOMSEARCH-5 échouent complètement (0/15) ; Ce comportement est attendu, car les méthodes de recherche aléatoire pure souffrent fortement de la dimension du problème et de l'absence de mécanisme d'apprentissage [4].. Cela souligne la complexité du paysage d'optimisation et les limites des méthodes étudiées.

RANDOMSEARCH-5, quant à lui, ne parvient à résoudre aucune fonction dans les conditions testées (0/15 pour toutes les fonctions), ce qui confirme son rôle de référence de base.

Globalement, ces résultats montrent que BIPOP-CMA-ES est l'algorithme le plus robuste, capable de maintenir un taux de succès élevé même sur des fonctions difficiles. À l'inverse, PSO-BFGS est performant uniquement sur des fonctions simples, mais perd en efficacité dès que la complexité du paysage augmente.

Cette analyse confirme que le choix de l'algorithme dépend fortement du type de problème, et met en évidence l'importance de la capacité d'exploration dans les problèmes multimodaux.

4) Taux de succès: Le tableau I résume le nombre de runs ayant atteint la cible $\Delta f \leq 10^{-2}$ pour chaque algorithme et chaque fonction.

TABLE I
TAUX DE SUCCÈS ($\Delta f \leq 10^{-2}$, DIM=10).

Fonction	CMA-ES	PSO-BFGS	RS-5
f1	15/15	15/15	0/15
f8	15/15	15/15	0/15
f15	15/15	0/15	0/15
f20	15/15	1/15	0/15
f24	1/15	0/15	0/15

Ce tableau confirme quantitativement les observations issues des courbes ECDF. BIPOP-CMA-ES atteint un taux de succès parfait (15/15) sur les fonctions f1, f8, f15 et f20, et reste le seul algorithme capable de résoudre f24, bien que dans un seul run. PSO-BFGS n'est compétitif que sur les fonctions unimodales (f1 et f8). RANDOMSEARCH-5 ne résout aucune fonction à cette précision.

5) ERT (Expected Running Time): L'ERT (Expected Running Time) est la métrique standard du benchmarking BBOB [1]. Elle mesure le nombre espéré d'évaluations nécessaires pour atteindre une précision cible Δf_{target}, en tenant compte des runs échoués :

$$\text{ERT}(\Delta f_{\text{target}}) = \frac{\sum_{i=1}^{n_{\text{runs}}} \text{evals}_i}{n_{\text{succ}}} \tag{1}$$

où evals_i est le nombre total d'évaluations du run i (budget complet si échec, nombre d'évaluations au moment de l'atteinte de la cible si succès), et n_{succ} est le nombre de runs ayant atteint la cible. Si aucun run ne réussit ($n_{\text{succ}} = 0$), l'ERT est défini comme ∞.

Cette métrique pénalise les algorithmes peu fiables : un algorithme ayant un taux de succès faible verra son ERT augmenter fortement, car les budgets des runs échoués s'ajoutent au numérateur sans contribuer au dénominateur.

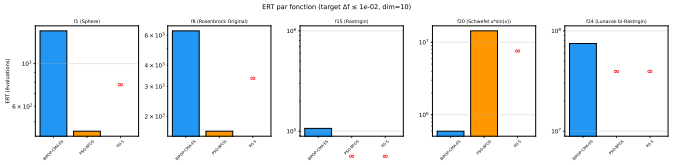

FIGURE 8. ERT par fonction pour $\Delta f \leq 10^{-2}$ (dim=10). Le symbole ∞ indique qu'aucun run n'a atteint la cible.

TABLE II
ERT POUR $\Delta f \leq 10^{-2}$ (DIM=10). ∞ = AUCUN RUN N'A ATTEINT LA CIBLE.

Fonction	CMA-ES	PSO-BFGS	RS-5
f1	4.68×10^3	3.07×10^2	∞
f8	6.27×10^3	1.15×10^3	∞
f15	1.15×10^5	∞	∞
f20	1.24×10^6	∞	∞
f24	7.28×10^7	∞	∞

La figure 8 et le tableau II présentent l'ERT pour une cible $\Delta f \leq 10^{-2}$.

Sur les fonctions unimodales (f1 et f8), PSO-BFGS présente l'ERT le plus faible, nécessitant environ 3×10^2 évaluations sur f1 contre 4.68×10^3 pour BIPOP-CMA-ES. Cet avantage d'un ordre de grandeur confirme l'efficacité de la composante BFGS pour l'exploitation locale sur des paysages simples.

Sur les fonctions multimodales (f15, f20 et f24), la situation s'inverse de manière radicale. PSO-BFGS et RANDOMSEARCH-5 présentent un ERT infini, car aucun run (ou presque) n'atteint la cible. BIPOP-CMA-ES est le seul algorithme capable de résoudre ces problèmes, bien que le coût augmente fortement avec la difficulté : de 1.15×10^5 évaluations sur f15 à 7.28×10^7 sur f24.

Cette analyse par l'ERT quantifie précisément le compromis entre les algorithmes : PSO-BFGS est jusqu'à 15 fois plus rapide sur les fonctions simples, mais totalement inefficace sur les fonctions complexes, tandis que BIPOP-CMA-ES offre une couverture complète au prix d'un coût computationnel plus élevé sur les cas faciles.

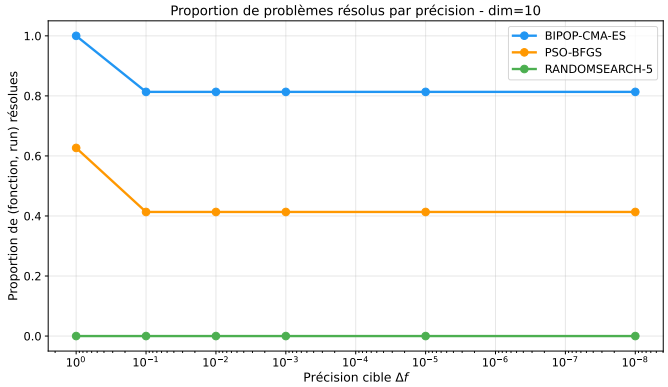

FIGURE 9. Proportion de problèmes résolus en fonction de la précision cible Δf (dim=10).

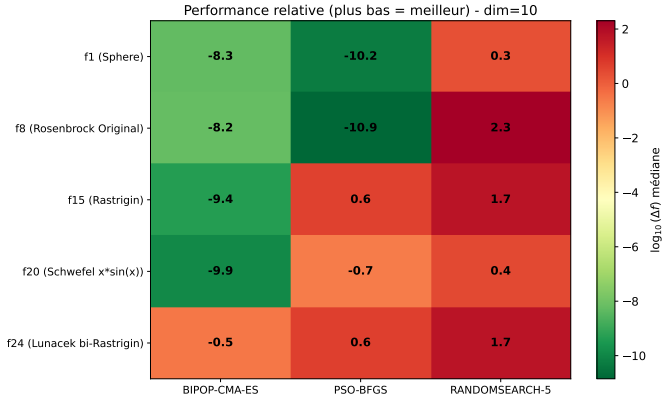

FIGURE 10. Heatmap des performances relatives ($\log_{10}(\Delta f)$ médiane) pour chaque algorithme et fonction (dim=10).

6) Proportion de problèmes résolus par précision: La figure 9 présente la proportion de problèmes résolus par chaque algorithme en fonction du seuil de précision Δf. Cette analyse permet d'évaluer la capacité des méthodes à atteindre des solutions de plus en plus précises.

On observe que BIPOP-CMA-ES atteint une performance maximale pour des seuils peu contraignants ($\Delta f \leq 10^0$), résolvant la totalité des problèmes (proportion égale à 1). Lorsque le seuil devient plus strict, sa performance diminue légèrement mais reste élevée, se stabilisant autour de 80% des problèmes résolus. Cela confirme sa robustesse et sa capacité à atteindre des solutions de haute précision.

PSO-BFGS présente un comportement différent. Il atteint environ 60% de problèmes résolus pour des seuils faibles, mais sa performance chute rapidement et se stabilise autour de 40% lorsque la précision demandée augmente. Cela indique que l'algorithme est efficace pour atteindre des solutions approximatives, mais rencontre des difficultés pour affiner les résultats.

RANDOMSEARCH-5, quant à lui, ne parvient à résoudre aucun problème, quelle que soit la précision demandée. Sa courbe reste nulle sur toute la plage de valeurs, ce qui confirme son inefficacité dans ce contexte.

Cette analyse met en évidence une différence fondamentale entre les algorithmes. BIPOP-CMA-ES se distingue par sa capacité à maintenir de bonnes performances même lorsque la précision exigée augmente, tandis que PSO-BFGS est limité dans sa capacité à atteindre des solutions très précises.

7) Heatmap des performances: La figure 10 présente une visualisation globale des performances des algorithmes à l'aide d'une heatmap, basée sur la médiane de $\log_{10}(\Delta f)$. Les valeurs les plus faibles (en vert) correspondent aux meilleures performances, tandis que les valeurs élevées (en rouge) indiquent des résultats moins précis.

Sur les fonctions simples, telles que f1 (Sphere) et f8 (Rosenbrock), PSO-BFGS obtient les meilleures performances, avec des valeurs très faibles (par exemple -10.2 et -10.9), indiquant une excellente précision. BIPOP-CMA-ES obtient également de bons résultats, bien que légèrement moins performants sur ces fonctions. RANDOMSEARCH-5 présente des performances nettement inférieures.

En revanche, sur les fonctions multimodales, les tendances s'inversent. Sur f15 (Rastrigin) et f20 (Schwefel), BIPOP-CMA-ES obtient les meilleures performances (valeurs proches de -9.4 et -9.9), tandis que PSO-BFGS présente des résultats beaucoup plus faibles, voire positifs, traduisant une difficulté à atteindre des solutions précises. RANDOMSEARCH-5 reste peu performant dans tous les cas.

Sur la fonction f24 (Lunacek), considérée comme très difficile, les performances de tous les algorithmes se dégradent fortement. BIPOP-CMA-ES reste néanmoins le meilleur avec une valeur autour de -0.5, tandis que PSO-BFGS et RANDOMSEARCH-5 présentent des résultats encore plus faibles.

Cette visualisation met clairement en évidence un comportement complémentaire entre les algorithmes. PSO-BFGS est particulièrement adapté aux fonctions simples et bien structurées, tandis que BIPOP-CMA-ES se distingue par sa robustesse sur les fonctions complexes et multimodales.

8) Tableau récapitulatif: Afin de résumer les performances des algorithmes, nous utilisons la médiane des valeurs finales de Δf sur les différents runs. La médiane est définie comme la valeur centrale d'un ensemble ordonné :

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{si } n \text{ est impair} \\ \frac{1}{2}\left(x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}\right) & \text{si } n \text{ est pair} \end{cases} \tag{2}$$

où $x_{(i)}$ désigne les valeurs triées par ordre croissant. Cette mesure est robuste aux valeurs extrêmes et permet de mieux représenter la performance typique des algorithmes stochastiques.

TABLE III
MÉDIANE DE Δf (DIM=10).

Fonction	CMA-ES	PSO-BFGS	RS-5
f1	5.41×10^{-9}	5.80×10^{-11}	1.98
f8	6.08×10^{-9}	1.41×10^{-11}	2.01×10^{2}
f15	4.44×10^{-10}	3.98	5.45×10^{1}
f20	1.33×10^{-10}	2.17×10^{-1}	2.58
f24	2.99×10^{-1}	4.33	5.29×10^{1}

Le tableau III présente la médiane de l'erreur finale Δf obtenue par chaque algorithme sur les différentes fonctions testées.

Sur les fonctions simples (f1 et f8), PSO-BFGS obtient les meilleures performances, avec des erreurs extrêmement faibles (de l'ordre de 10^{-11}), ce qui traduit une convergence très rapide et précise. BIPOP-CMA-ES atteint également de bonnes performances, bien que légèrement inférieures. RANDOMSEARCH-5 reste très largement en retrait.

Sur les fonctions multimodales (f15 et f20), la tendance s'inverse. BIPOP-CMA-ES obtient des erreurs très faibles (de l'ordre de 10^{-10}), tandis que PSO-BFGS présente des erreurs beaucoup plus élevées, indiquant une difficulté à éviter les minima locaux. RANDOMSEARCH-5 confirme ses faibles performances.

Sur la fonction difficile f24 (Lunacek), tous les algorithmes rencontrent des difficultés, mais BIPOP-CMA-ES reste le plus performant avec une erreur inférieure à 1, contrairement à PSO-BFGS et RANDOMSEARCH-5 qui présentent des erreurs nettement plus importantes.

Ces résultats confirment les observations issues des analyses précédentes. PSO-BFGS est particulièrement efficace sur les fonctions simples et bien structurées, tandis que BIPOP-CMA-ES se distingue par sa robustesse et sa capacité à traiter des paysages complexes. RANDOMSEARCH-5 constitue une référence de base, mais reste largement inférieur aux autres méthodes.

9) Tests de Wilcoxon: Afin de comparer rigoureusement les performances des algorithmes, nous utilisons le test non paramétrique de Wilcoxon pour échantillons appariés. Ce test permet d'évaluer si deux méthodes présentent des différences significatives sans supposer de distribution normale.

Soient deux séries de résultats appariés (x_i, y_i) correspondant aux performances de deux algorithmes. On considère les différences :

$$d_i = x_i - y_i \tag{3}$$

On classe ensuite les valeurs absolues $|d_i|$ et on leur attribue des rangs R_i. La statistique de test est donnée par :

$$W = \sum_i \text{sign}(d_i)\, R_i \tag{4}$$

Sous l'hypothèse nulle H_0 (absence de différence entre les algorithmes), on calcule une p-value. Si $p < \alpha = 0.05$, la différence est considérée comme statistiquement significative.

TABLE IV
TESTS DE WILCOXON ($p < 0.05$ SIGNIFICATIF).

Fonction	CMA vs PSO	CMA vs RS	PSO vs RS
f1	6.10×10^{-5}	6.10×10^{-5}	6.10×10^{-5}
f8	6.10×10^{-5}	6.10×10^{-5}	6.10×10^{-5}
f15	6.10×10^{-5}	6.10×10^{-5}	6.10×10^{-5}
f20	1.22×10^{-4}	6.10×10^{-5}	6.10×10^{-5}
f24	6.10×10^{-5}	6.10×10^{-5}	6.10×10^{-5}

Le tableau IV présente les résultats des tests statistiques de Wilcoxon effectués pour comparer les performances des algorithmes deux à deux.

On observe que toutes les valeurs de p sont inférieures au seuil de significativité fixé ($\alpha = 0.05$). Cela indique que les différences de performances observées entre les algorithmes sont statistiquement significatives pour l'ensemble des fonctions étudiées.

En particulier, la comparaison entre BIPOP-CMA-ES et PSO-BFGS met en évidence des différences significatives sur toutes les fonctions. Cela confirme que les deux algorithmes présentent des comportements distincts selon la structure du problème : PSO-BFGS est plus performant sur les fonctions simples, tandis que BIPOP-CMA-ES domine sur les fonctions complexes et multimodales.

La comparaison avec RANDOMSEARCH-5 montre également des différences significatives dans tous les cas, ce qui confirme que cette méthode constitue une référence de base nettement moins performante que les deux autres algorithmes.

Ces résultats renforcent la validité des analyses précédentes en apportant une confirmation statistique rigoureuse. Ils montrent que les écarts observés ne sont pas dus au hasard, mais reflètent des différences réelles dans les capacités des algorithmes.

V. RECOMMANDATION

Sur la base des analyses précédentes, nous formulons des recommandations pratiques quant au choix de l'algorithme en fonction du type de problème et du budget d'évaluations disponible.

A. Définition des budgets

Nous distinguons trois niveaux de budget d'évaluations, exprimés en fonction de la dimension $D = 10$:

- **Petit budget** : $\leq 10^2 \cdot D$ évaluations ($\leq 10^3$ évaluations) ;
- **Budget moyen** : entre $10^2 \cdot D$ et $10^4 \cdot D$ évaluations (10^3 à 10^5 évaluations) ;
- **Grand budget** : $\geq 10^4 \cdot D$ évaluations ($\geq 10^5$ évaluations).

B. Recommandation par type de fonction

Fonctions unimodales (f1, f8). Pour les fonctions simples et bien structurées, **PSO-BFGS est recommandé** avec un petit ou moyen budget. L'analyse ERT montre qu'il atteint la cible $\Delta f \leq 10^{-2}$ en seulement 3.07×10^2 évaluations sur f1, soit environ 15 fois moins que BIPOP-CMA-ES (tableau II). Avec un grand budget, les deux algorithmes atteignent des précisions similaires, mais PSO-BFGS y parvient plus rapidement.

Fonctions multimodales (f15, f20, f24). Sur les fonctions multimodales, **BIPOP-CMA-ES est l'algorithme recommandé** quel que soit le budget d'évaluations disponible. Plusieurs éléments justifient cette recommandation :

- **Taux de succès** : BIPOP-CMA-ES atteint un taux de succès de 15/15 sur f15 et f20, contre 0/15 pour PSO-BFGS sur ces mêmes fonctions (tableau I) ;
- **ERT** : BIPOP-CMA-ES est le seul algorithme présentant un ERT fini sur f15, f20 et f24 (tableau II), ce qui signifie que PSO-BFGS et RANDOMSEARCH-5 sont incapables d'atteindre la cible quel que soit le budget ;
- **Précision finale** : la médiane de Δf obtenue par BIPOP-CMA-ES est de l'ordre de 10^{-10} sur f15 et f20, contre des valeurs supérieures à 10^0 pour PSO-BFGS, soit un écart de plus de dix ordres de grandeur (tableau III) ;
- **Robustesse** : la faible variabilité entre les 15 runs confirme la stabilité de BIPOP-CMA-ES, même sur des paysages fortement irréguliers ;
- **Mécanisme de redémarrage adaptatif** : grâce à sa stratégie bi-population, BIPOP-CMA-ES parvient à échapper aux minima locaux là où PSO-BFGS reste piégé.

Sur la fonction f24 (Lunacek), considérée comme la plus difficile, BIPOP-CMA-ES reste le meilleur algorithme disponible avec une médiane de $\Delta f \approx 2.99 \times 10^{-1}$, contre 4.33 pour PSO-BFGS et 5.29×10^1 pour RANDOMSEARCH-5. Bien que les performances de tous les algorithmes se dégradent sur cette fonction, BIPOP-CMA-ES conserve un avantage significatif, confirmé par les tests de Wilcoxon ($p < 0.05$).

VI. Conclusions

Ce travail a proposé une analyse comparative approfondie de trois algorithmes d'optimisation boîte noire — BIPOP-CMA-ES, PSO-BFGS et RANDOMSEARCH-5 — sur un sous-ensemble représentatif de la suite de benchmarks BBOB en dimension $D = 10$. L'étude s'est appuyée sur l'analyse détaillée des données d'exécution, en considérant à la fois des runs individuels et des agrégations statistiques sur plusieurs instances.

Les résultats obtenus mettent en évidence des différences significatives entre les approches étudiées. BIPOP-CMA-ES s'impose comme l'algorithme le plus robuste et le plus performant sur les fonctions complexes et multimodales, grâce à sa capacité d'adaptation et à son mécanisme de redémarrage. À l'inverse, PSO-BFGS se distingue par sa rapidité de convergence sur les fonctions simples et bien structurées, bénéficiant de sa composante d'optimisation locale. RANDOMSEARCH-5, bien que simple, joue un rôle essentiel de référence, permettant de quantifier les gains apportés par des méthodes plus sophistiquées.

L'analyse croisée à l'aide de courbes de convergence, de boxplots, de fonctions ECDF, de l'ERT, de heatmaps et de tests statistiques de Wilcoxon a permis de confirmer que les performances des algorithmes dépendent fortement des caractéristiques du problème. En particulier, l'ERT a mis en évidence que PSO-BFGS est jusqu'à 15 fois plus rapide que BIPOP-CMA-ES sur les fonctions unimodales, mais présente un temps d'exécution infini sur les fonctions multimodales.

Aucun algorithme ne se révèle universellement optimal, ce qui souligne l'importance d'adapter le choix de la méthode au type de fonction et au budget d'évaluations disponible.

Ces résultats mettent en évidence un compromis fondamental entre vitesse de convergence, précision et robustesse. Les méthodes hybrides sont particulièrement efficaces sur les paysages simples, tandis que les approches évolutionnaires sont mieux adaptées aux problèmes difficiles et fortement multimodaux.

Dans une perspective future, plusieurs extensions peuvent être envisagées. Il serait pertinent d'élargir cette étude à différentes dimensions ($D \in \{2, 5, 20\}$) ainsi qu'à l'ensemble des fonctions de la suite BBOB, afin de mieux caractériser l'impact de la dimension sur les performances. L'intégration d'autres algorithmes d'optimisation, notamment des approches récentes basées sur l'apprentissage automatique, constituerait également une piste intéressante. Enfin, une analyse plus approfondie du coût computationnel et de la complexité algorithmique permettrait de compléter cette étude.

En conclusion, ce travail confirme que l'optimisation boîte noire reste un domaine où le choix de l'algorithme est fortement dépendant du contexte, et qu'une analyse expérimentale rigoureuse constitue un outil essentiel pour guider ce choix.

Références

[1] N. Hansen, A. Auger, R. Ros, O. Mersmann, T. Tušar, and D. Brockhoff, "COCO : A platform for comparing continuous optimizers in a black-box setting," *Optimization Methods and Software*, vol. 36, no. 1, pp. 114–144, 2021.

[2] N. Hansen, "Benchmarking a BI-Population CMA-ES on the BBOB-2009 function testbed," in *Proc. GECCO Companion*, pp. 2389–2396, 2009.

[3] C. Voglis, K.E. Parsopoulos, D.G. Papageorgiou, I.E. Lagaris, and M.N. Vrahatis, "MEMPSODE : A global optimization software based on hybridization of population-based algorithms and local searches," *Computer Physics Communications*, vol. 183, pp. 1139–1154, 2012.

[4] A. Auger and R. Ros, "Benchmarking the pure random search on the BBOB-2009 testbed," in *Proc. GECCO Companion*, 2009.

[5] D. Brockhoff, "COCO BBOB Benchmark Data for RANDOMSEARCH-5," 2017. [Online]. Available : https://numbbo.github.io/data-archive/

[6] numbbo, "BBOB Data Archive," https://numbbo.github.io/data-archive/, consulté en 2024.